

Análisis de datos

Olist Ecommerce



Autor: Jack Carpio

Índice de contenido

1	Introducción	5
2	Problema	5
3	Solución propuesta	5
4	Características del dataset	6
5	Estructura del data set	6
5.1	Customers	7
5.2	Sellers	7
5.3	Orders	8
5.4	Order reviews	9
5.5	Product category name translation	9
5.6	Products	10
5.7	Order items	10
5.8	Order payments	10
6	Exploración y transformación	11
6.1	Customers	11
6.2	Sellers	11
6.3	Orders	12
6.3.1	Redefinición de “customers”	12
6.4	Order reviews	12
6.5	Product category name translation	13
6.6	Products	13
6.7	Order items	14
6.7.1	Redefinición de “sellers”	14
6.8	Order payments	14
7	Limpieza y redefinición de dataframes	14
8	Análisis	17
8.1	Finanzas	17
8.1.1	Evolución Mensual	17
8.1.2	Desempeño de vendedores	18
8.1.3	Distribución de métodos de pago	19
8.2	Comercial	19
8.2.1	Análisis por categoría - 2017	19
8.2.2	Análisis por estado	20
8.3	Logística	22
8.3.1	Distribución de estado de pedidos	22
8.3.2	Distribución de tiempos de entrega	22
8.3.3	Tasa de demoras por estado	22
8.3.4	Tasa de demoras por vendedor	23
8.4	Calidad	24
8.4.1	Reseñas generales por vendedor	24

8.4.2	<i>Relación entre entregas y satisfacción de clientes</i>	24
8.4.3	<i>Relación entre tasas de demora y review score promedio.....</i>	25
9	<i>Conclusiones.....</i>	27
10	<i>Anexo: Estructura de tablas</i>	28

Índice de figuras

Figura 1 Relaciones entre tablas sin procesar.....	7
Figura 2 Evolución del estado de un pedido.....	8
Figura 3 Evolución mensual de pedidos.....	17
Figura 4 Evolución mensual de ingresos brutos	18
Figura 5 Top 20 vendedores por volumen de pedidos.....	18
Figura 6 Top 20 vendedores por facturación	19
Figura 7 Top 20 categorías por volumen de pedidos	20
Figura 8 Top 20 categorías por facturación	20
Figura 9 Clientes por estado	21
Figura 10 Ingresos brutos por estado	21
Figura 11 Distribución de tiempos de entrega	22
Figura 12 Tasas de demora por estado	23
Figura 13 Top 20 vendedores por tasa de demora.....	24
Figura 14 Distribución de reseñas para entregas a tiempo y entregas atrasadas.....	25
Figura 15 Review score promedio por rangos de adelanto o atraso	25
Figura 16 Relación entre tasas de demora y review score promedio por estado.....	26

Índice de tablas

Tabla 1 Clientes - sin procesar.....	7
Tabla 2 Vendedores - sin procesar	8
Tabla 3 Pedidos - sin procesar.....	9
Tabla 4 Reseñas - sin procesar	9
Tabla 5 Traducción de nombres de categorías - sin procesar	9
Tabla 6 Productos - sin procesar	10
Tabla 7 Artículos de pedidos - sin procesar.....	10
Tabla 8 Pagos de pedidos - sin procesar	11
Tabla 9 Clientes.....	11
Tabla 10 Vendedores.....	12
Tabla 11 Pedidos.....	12
Tabla 12 Muestra de pedidos asociados a más de una reseña	13
Tabla 13 Reseñas	13
Tabla 14 Traducción de nombres de categorías.....	13
Tabla 15 Productos	14
Tabla 16 Artículos de pedidos	14
Tabla 17 Pagos de pedidos.....	14
Tabla 18 Muestra de pedidos con fechas inconsistentes	15
Tabla 19 Muestra de pedidos entregados sin fecha de entrega	15
Tabla 20 Pedidos no entregados con fecha de entrega	15
Tabla 21 Muestra de pedidos con fechas de reseñas inconsistentes	15
Tabla 22 Pedidos sin método de pago definido.....	15
Tabla 23 Relaciones entre tablas procesadas	16
Tabla 24 Distribución de métodos de pago.....	19
Tabla 25 Distribución de estado de pedidos.....	22
Tabla 26 Muestra de reseñas generales por vendedor	24

1 Introducción

Olist es una empresa brasileña que conecta comerciantes con distintos marketplaces de comercio electrónico, funcionando como una plataforma que facilita la venta de productos y la gestión de pedidos dentro del ecosistema digital de Brasil.

Esos comerciantes pueden vender sus productos a través de Olist Store y enviarlos directamente a los clientes utilizando los socios logísticos de Olist.

Después de que un cliente compra el producto en Olist Store, se notifica al vendedor para que cumpla con ese pedido. Una vez que el cliente recibe el producto, o vence la fecha estimada de entrega, recibe una encuesta de satisfacción por correo electrónico donde puede dar una nota sobre la experiencia de compra y escribir algunos comentarios.

2 Problema

El crecimiento de una plataforma de comercio electrónico depende de múltiples factores, entre ellos la satisfacción de los clientes, el desempeño de los vendedores, la eficiencia logística y la evolución de la demanda. Aunque el ecosistema de Olist registra información detallada sobre estos procesos, la gran cantidad de datos distribuidos en múltiples tablas dificulta obtener una visión integral del negocio y detectar oportunidades de mejora.

Sin un análisis estructurado resulta complejo identificar qué categorías impulsan las ventas, qué regiones presentan mayor potencial de crecimiento, cuáles son los principales problemas logísticos o cómo influyen los tiempos de entrega en la satisfacción de los clientes. Asimismo, la ausencia de indicadores consolidados limita la capacidad para priorizar acciones comerciales y operativas basadas en evidencia.

3 Solución propuesta

Frente al problema, se plantea el desarrollo de un análisis integral del e-commerce de Olist que permita transformar los datos disponibles en información útil para la toma de decisiones. A través de procesos de limpieza y preparación de datos, consultas analíticas y visualizaciones interactivas, el proyecto busca identificar patrones de comportamiento, medir indicadores clave de desempeño y generar recomendaciones orientadas a mejorar la operación del negocio.

El objetivo de este proyecto es desarrollar un análisis integral del e-commerce de Olist utilizando **Python, SQL y Power BI**, a lo largo del proyecto se buscará:

- Explorar y limpiar los datos
- Construir un modelo analítico consistente
- Definir métricas clave de negocio
- Analizar tendencias de ventas, entregas y satisfacción
- Diseñar un dashboard interactivo en Power BI
- Extraer conclusiones accionables para la toma de decisiones

Algunas de las preguntas que orientarán el trabajo son:

- ¿Cómo evoluciona la demanda a lo largo del tiempo?
- ¿Qué categorías de productos generan más ventas?
- ¿Qué impacto tiene la demora en la entrega sobre la valoración del cliente?
- ¿Qué vendedores influyen considerablemente en la plataforma?
- ¿En qué regiones se concentran las mayores oportunidades y los principales problemas logísticos?
- ¿Qué indicadores ayudan a identificar una mala experiencia del cliente?

Para responder estas preguntas, el proyecto se desarrollará en tres etapas complementarias:

Python para exploración, limpieza, validación y análisis exploratorio de datos.

SQL para modelado relacional, creación de métricas y consultas analíticas.

Power BI para la visualización final y la construcción de un dashboard orientado a negocio.

4 Características del dataset

El data set público de Olist reúne información de aproximadamente **100.000 pedidos** realizados entre **2016 y 2018**, y constituye una base muy rica para analizar el desempeño comercial, logístico y de experiencia del cliente en un entorno de e-commerce real.

Algo importante a destacar es que para 2016 solo se tienen registros incompletos de los últimos 2 meses, por lo que no vale la pena analizar ese periodo, para este proyecto solo analizaremos los datos a partir de 2017.

Este conjunto de datos contiene tablas relacionadas con distintos procesos del negocio, incluyendo información de **clientes, pedidos, ítems de pedido, pagos, reseñas, productos, vendedores y geolocalización**. Gracias a esta estructura, es posible reconstruir el recorrido completo de una compra: desde que el cliente realiza el pedido hasta que el producto es entregado y evaluado.

Esto lo convierte en una excelente base para responder preguntas de negocio vinculadas con crecimiento, rentabilidad, logística, satisfacción del cliente y rendimiento de vendedores o categorías.

Fuente: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

En este proyecto se debe entender como “pedido” u “orden de compra” al pedido que se le hace a un vendedor para una compra dada, es decir si un cliente realiza **una compra** que será provista por 2 vendedores, se genera un pedido (u orden de compra) para cada vendedor.

IMPORTANTE: Una compra puede tener varios artículos incluidos y cada artículo puede ser entregado por un vendedor distinto.


Sitio web: www.olist.com

5 Estructura del data set

Para algunas columnas de algunas tablas no se encontró documentación que indiquen de manera confiable y coherente el significado de dichas columnas y su relación con el resto de tablas, pero se pudieron deducir a partir de un extenso análisis del dataset.

En la imagen siguiente se observa un esquema inicial de las tablas y sus relaciones.

Figura 1 Relaciones entre tablas sin procesar



No se importó la tabla de geolocalización ya que no aporta información relevante para este análisis.

5.1 Customers

Esta tabla contiene información del cliente, incluidos identificadores únicos, detalles de ubicación como código postal, ciudad y estado de los clientes en Brasil.

- **customer_id** (cadena): Identificador que vincula de manera **única** a cada pedido (order_id) con cada cliente (customer_unique_id).

Se puede interpretar como un ID que vincula de manera única a un cliente con un pedido (order_id).

- **customer_unique_id** (cadena): Identificador **único** de cada cliente
- **customer_zip_code_prefix** (numérico): Primeros cinco dígitos del código postal del cliente
- **customer_city** (categórico): Ciudad correspondiente al cliente (customer_unique_id)
- **customer_state** (categórico): Estado (abreviado) correspondiente al cliente (customer_unique_id)

Tabla 1 Clientes - sin procesar

customer_id	customer_unique_id	customer_zip_code_prefix	customer_city	customer_state
06b8999e2fba1a	861eff4711a542e4b938	14409	franca	SP
18955e83d337fd	290c77bc529b7ac935b9	9790	sao bernardo d	SP
4e7b3e00288586	060e732b5b29e8181a1	1151	sao paulo	SP
b2b6027bc5c510	259dac757896d24d770	8775	mogi das cruze	SP

5.2 Sellers

Esta tabla contiene información sobre los vendedores en el mercado de Olist, incluidos sus identificadores únicos y ubicaciones geográficas en Brasil.

- **seller_id** (cadena): Identificador **único** de cada vendedor
- **seller_zip_code_prefix** (numérico): Primeros cinco dígitos del código postal del vendedor
- **seller_city** (categórico): Ciudad correspondiente al vendedor
- **seller_state** (categórico): Estado (abreviado) correspondiente al vendedor

Tabla 2 Vendedores - sin procesar

seller_id	seller_zip_code_prefix	seller_city	seller_state
3442f8959a84	13023	campinas	SP
d1b65fc7deb0	13844	mogi guacu	SP
ce3ad9de9600	20031	rio de janeiro	RJ
c0f3eea2e140	4195	sao paulo	SP

5.3 Orders

Esta tabla contiene información detallada sobre las entregas de pedidos, incluido el estado del pedido, las marcas de tiempo de compra y aprobación de compra, las fechas de entrega al transportista, las fechas de entrega al cliente y las fechas de entrega estimadas.

- **order_id** (cadena): Identificador **único** de cada pedido

Distintos pedidos pueden estar asociados al mismo cliente, si un cliente realiza una **compra** que involucra a más de un vendedor, se generará un “order_id” distinto para cada vendedor, es decir cada “order_id” está relacionado a un único vendedor.

- **customer_id** (cadena): Identificador que vincula de manera **única** a cada pedido (order_id) con cada cliente (customer_unique_id)
- **order_status** (categórico): Estado **final** observado de un pedido

En total hay 8 posibles estados y, según [documentación](#) oficial de Olist, el estado de una compra puede evolucionar como se representa en la imagen siguiente, se muestra también una descripción de cada estado.

created: Orden generada

shipped: Pedido despachado

approved: Pago confirmado

delivered: Pedido completado


processing: Preparación del pedido

unavailable: Compra fallida por problemas operativos

invoiced: Factura emitida

canceled: Compra cancelada

Figura 2 Evolución del estado de un pedido



- **order_purchase_timestamp** (fecha): Fecha y hora de creación de pedido
- **order_approved_at** (fecha): Fecha y hora de aprobación de pedido

- **order_delivered_carrier_date** (fecha): Fecha y hora de envío del pedido a través del transportista
- **order_delivered_customer_date** (fecha): Fecha y hora de entrega del pedido al cliente
- **order_estimated_delivery_date** (fecha): Fecha estimada de entrega del pedido al cliente

Algo importante a destacar es que aunque 2 o más pedidos sean parte de una misma compra, las fechas de entrega estimada y efectiva pueden ser distintas, ya que cada vendedor maneja sus pedidos independientemente y pueden enviarlas en fechas distintas.

Tabla 3 Pedidos - sin procesar

order_id	customer_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estimated_delivery_date
e481f51cbdc	9ef432eb6251	delivered	02/10/2017 10:56	02/10/2017 11:07	04/10/2017 19:55	10/10/2017 21:25	18/10/2017 00:00
53cdb2fc8bc	b0830fb4747a	delivered	24/07/2018 20:41	26/07/2018 03:24	26/07/2018 14:31	07/08/2018 15:27	13/08/2018 00:00
47770eb910c	41ce2a54c0b0	delivered	08/08/2018 08:38	08/08/2018 08:55	08/08/2018 13:50	17/08/2018 18:06	04/09/2018 00:00
949d5b44dbf	f88197465ea7	delivered	18/11/2017 19:28	18/11/2017 19:45	22/11/2017 13:39	02/12/2017 00:28	15/12/2017 00:00

5.4 Order reviews

Esta tabla contiene información sobre las opiniones de los clientes sobre los pedidos, incluidos puntajes, comentarios, fechas de creación de reseñas y fechas de respuesta.

- **review_id** (cadena): Identificador **único** de cada reseña
- **order_id** (cadena): Identificador **único** de un pedido
- **review_score** (numérico): Puntaje de 1-5
- **review_comment_title** (cadena): Título
- **review_comment_message** (cadena): Comentario
- **review_creation_date** (fecha): Fecha de creación
- **review_answer_timestamp** (fecha): Fecha y hora de respuesta

Una misma reseña (review_id) puede estar asociada a más de un pedido (order_id), ya que varios pedidos pueden estar asociados a una misma **compra**, además existen pedidos que están asociados a más de una de reseña, esto puede explicarse debido a que algunos usuarios realizan más de una reseña, ya sea positiva o negativa.

Para los casos donde una compra involucra más de un pedido, la reseña está disponible después de que lleguen **todos** los pedidos o se venza el plazo de entrega de **algún** pedido.

Tabla 4 Reseñas - sin procesar

review_id	order_id	review_score	review_comment_title	review_comment_message	review_creation_date	review_answer_timestamp
7bc2406110b	73fc7af87114	4			18/01/2018 00:00	18/01/2018 21:46
80e641a11e5	a548910a1c6	5			10/03/2018 00:00	11/03/2018 03:05
228ce5500dc	f9e4b658b20	5			17/02/2018 00:00	18/02/2018 14:36
e64fb393e7b	658677c97b3	5		Recebi bem antes do prazo e	21/04/2017 00:00	21/04/2017 22:02

5.5 Product category name translation

Esta tabla proporciona un mapeo de los nombres de las categorías de productos del portugués brasileño al inglés, facilitando la traducción y categorización de productos en el mercado Olist.

- **product_category_name** (categórico): Nombre en portugués para categorías de productos
- **product_category_name_english** (categórico): Traducción al inglés del nombre de la categoría de producto correspondiente

Tabla 5 Traducción de nombres de categorías - sin procesar

product_category_name	product_category_name_english
beleza_saude	health_beauty
informatica_acessorios	computers_accessories
automotivo	auto
cama_mesa_banho	bed_bath_table

5.6 Products

Esta tabla contiene información detallada sobre los productos vendidos en la plataforma Olist, incluidos sus identificadores únicos, categorías, dimensiones y atributos descriptivos.

- **product_id** (cadena): Identificador **único** para cada producto
- **product_category_name** (categórico): Nombre de la categoría del producto en portugués
- **product_name_lenght** (numérico): Longitud del nombre del producto en caracteres
- **product_description_lenght** (numérico): Longitud de la descripción del producto en caracteres
- **product_photos_qty** (numérico): Número de fotos del producto
- **product_weight_g** (numérico): Peso del producto en gramos
- **product_length_cm** (numérico): Longitud del producto en centímetros
- **product_height_cm** (numérico): Altura del producto en centímetros
- **product_width_cm** (numérico): Ancho del producto en centímetros

Tabla 6 Productos - sin procesar

product_id	product_category_name	product_name_lenght	product_description_lenght	product_photos_qty	product_weight_g	product_length_cm	product_height_cm	product_width_cm
1e9e8ef04d	perfumaria	40	287	1	225	16	10	14
3aa071139cb	artes	44	276	1	1000	30	18	20
96bd76ec881	esporte_lazer	46	250	1	154	18	9	15
cef67bcfe19	bebes	27	261	1	371	26	4	26

5.7 Order items

Esta tabla contiene información sobre los artículos de cada pedido, incluidos identificadores de pedidos y productos, detalles del vendedor, fechas de envío, precios y valores de flete.

- **order_id** (cadena): Identificador **único** de cada pedido
- **order_item_id** (numérico): Número secuencial del item dentro de un pedido

También se puede interpretar como la cantidad de productos involucrados en un pedido, cada producto se cuenta individualmente sin importar si es de la misma clase.

- **product_id** (cadena): Identificador **único** de cada producto
- **seller_id** (cadena): Identificador **único** de cada vendedor
- **shipping_limit_date** (fecha): Fecha límite de envío del vendedor
- **price** (numérico): Precio individual de cada producto involucrado en un pedido
- **freight_value** (numérico): Valor individual del flete por cada producto involucrado en un pedido

Tabla 7 Artículos de pedidos - sin procesar

order_id	order_item_id	product_id	seller_id	shipping_limit_date	price	freight_value
0008288aa42	1	368c6c730842d7	1f50f920176fa	21/02/2018 02:55	49.9	13.37
0008288aa42	2	368c6c730842d7	1f50f920176fa	21/02/2018 02:55	49.9	13.37
00143d0f86d	1	e95ee6822b66a	a17f621c590e	20/10/2017 16:07	21.33	15.1
00143d0f86d	2	e95ee6822b66a	a17f621c590e	20/10/2017 16:07	21.33	15.1

5.8 Order payments

Esta tabla contiene información de pago de pedidos, incluido el ID del pedido, la secuencia de pago, el tipo de pago, el número de cuotas y el valor del pago.

- **order_id** (cadena): Identificador **único** de cada pedido
- **payment_sequential** (numérico): Indica el número de secuencias de pagos de un pedido si se utilizan varios métodos de pago

Un cliente puede utilizar múltiples métodos de pago, creando secuencias (1, 2, ...)

- **payment_type** (categórico): El método de pago utilizado para cada transacción

Métodos de pago existentes:

credit_card	Pago instantáneo con tarjeta de crédito
debit_card	Pago instantáneo con tarjeta de débito
voucher	Cupón, crédito o vale aplicado al pedido
boleto	Documento de pago que el cliente debe abonar posteriormente
not_defined	Método no especificado

- **payment_installments** (numérico): Número de cuotas elegidas por el cliente para el pago
- **payment_value** (numérico): El valor monetario de cada transacción de pago, indica el valor total por método de pago, no el valor de cada cuota

Tabla 8 Pagos de pedidos - sin procesar

order_id	payment_sequential	payment_type	payment_installments	payment_value
0016dfedd97	1	credit_card	5	52.63
0016dfedd97	2	voucher	1	17.92
002f19a65a2	1	voucher	1	44.11
002f19a65a2	2	voucher	1	33.18

6 Exploración y transformación

En esta etapa se analizó cada tabla y su relación con el resto del data set, teniendo esto en mente se gestionaron valores faltantes, se modificaron y/o algunas columnas con el objetivo de dejar el data set limpio y manejable y se filtraron registros inconsistentes con la estructura del dataset y las relaciones entre sus componentes.

6.1 Customers

Se reemplazó el identificador alpha numérico por un identificador numérico entero, facilitando así su manejo.

También, como respaldo, se creó un diccionario (dict_cust_uniq_id) para almacenar los “customer_unique_id” originales y los nuevos, y otro diccionario (dict_cust_id) para almacenar los “customer_id” con los nuevos identificadores únicos de clientes.

Para vincular a los clientes con sus pedidos (order_id) se podría usar directamente el identificador único de clientes (customer_unique_id), así que se eliminará la columna customer_id al ser innecesaria. Se repetía la información de algunos clientes, por lo que se eliminaron los duplicados.

Tabla 9 Clientes

customer_unique_id	customer_zip_code_prefix	customer_city	customer_state
1	14409	franca	SP
2	9790	sao bernardo d	SP
3	1151	sao paulo	SP
4	8775	mogi das cruze	SP
5	13056	campinas	SP

6.2 Sellers

Se reemplazó el identificador alpha numérico por un identificador numérico entero, también se creó un diccionario de respaldo (dict_seller_id) para almacenar los IDs originales y los nuevos.

Tabla 10 Vendedores

seller_id	seller_zip_code_prefix	seller_city	seller_state
1	13023	campinas	SP
2	13844	mogi guacu	SP
3	20031	rio de janeiro	RJ
4	4195	sao paulo	SP

6.3 Orders

Se encontraron valores nulos (null) en algunas marcas de tiempo del dataframe, no se eliminaron ya que razonablemente pueden estar asociados a pedidos que por alguna razón no se entregaron o fueron cancelados.

Reemplazamos los identificadores de la columna "customer_id" a partir del diccionario "dict_cust_id", y renombramos dicha columna como "customer_unique_id", de esta manera cada pedido queda directamente relacionado con un ID único de cliente.

También asignamos identificadores numéricos enteros para los pedidos (order_id) y creamos un diccionario de respaldo (dict_order_id).

La fecha estimada para la entrega del pedido está en formato fecha corta, es decir solo se indica el día de entrega estimada (no la hora), y en general se asume que un cliente estará satisfecho si el pedido llega en dicha fecha o una fecha anterior, por lo que, para este proyecto, no es necesario tener registros horarios, entonces se cambiará el formato a fecha corta en las columnas necesarias.

Se agregaron algunas columnas:

- delivery_days (numérico): Indica la diferencia entre día de compra y entrega de pedido, si existen los registros.
- advance_or_delay_days (numérico): Indica la diferencia entre entrega efectiva y entrega estimada, si existen los registros. Si el valor es negativo indica un atraso en la entrega, según días de atraso.

Como mencionamos anteriormente, los datos de 2016 son pocos e incompletos, por lo que no vale la pena analizar ese periodo, por lo que filtraremos para pedidos a partir del 2017-01-01.

Tabla 11 Pedidos

order_id	customer_unique_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estimated_delivery_date	delivery_days	advance_or_delay_days
1	68585	delivered	02/10/2017	02/10/2017	04/10/2017	10/10/2017	18/10/2017	8	8
2	74977	delivered	24/07/2018	26/07/2018	26/07/2018	07/08/2018	13/08/2018	14	6
3	555	delivered	08/08/2018	08/08/2018	08/08/2018	17/08/2018	04/09/2018	9	18
4	59790	delivered	18/11/2017	18/11/2017	22/11/2017	02/12/2017	15/12/2017	14	13
5	65715	delivered	13/02/2018	13/02/2018	14/02/2018	16/02/2018	26/02/2018	3	10

6.3.1 Redefinición de "customers"

Para que la estructura global sea coherente, debemos filtrar la tabla de clientes tal que solo incluiremos a los clientes con registros de pedidos.

6.4 Order reviews

Se encontraron valores nulos, es aceptable ya que no todas las personas dejan reseñas completas respecto a sus pedidos, o directamente no dejan reseñas.

En principio la columna "review_answer_timestamp" no nos aporta información valiosa, por lo que la eliminamos, y además convertimos a formato de fecha corta la columna "review_creation_date".

De la misma manera que hicimos con tablas previas, reemplazaremos los índices originales con índices numéricos enteros, se creó el diccionario “dict_review_id” para almacenar los IDs originales de las reseñas y los nuevos IDs asignados.

Como explicamos anteriormente, un mismo pedido puede estar asociado a más de una reseña, incluso con puntajes distintos.

Tabla 12 Muestra de pedidos asociados a más de una reseña

review_id	order_id	review_score	review_comment_title	review_comment_message	review_creation_date
21483	815	1	NaN	Realizei a compra de 2 colchas	12/04/2017
6770	815	4	NaN	NaN	09/04/2017
62256	1090	1	NaN	Ja tive problema com uma ma	14/12/2017
32199	1090	1	NaN	Acho um absurdo comprar um	16/12/2017
15410	1146	3	NaN	NaN	31/01/2018
2321	1146	4	NaN	NaN	24/01/2018
72556	1536	3	NaN	Não credito todo o erro ao for	04/01/2018
18664	1536	5	NaN	O produto foi entregue antes	16/12/2017

Para facilitar el análisis posterior y orientar los resultados a las deficiencias cometidas, para cada pedido asociado a más de una reseña, nos quedaremos con las reseñas a las que corresponda el menor puntaje y fecha más antigua, eliminando las restantes para cada pedido repetido. Por ejemplo, para el pedido con “order_id” = 815 eliminaremos la reseña con “review_id” = 6770, **asociada a ese pedido**. Para hacer esto trabajamos con los **índices** del dataframe, no empleamos los índices de las reseñas debido a que una misma reseña puede estar asociada a más de un pedido.

Finalmente, filtramos para pedidos posteriores a 2016 y que además estén incluidos en el dataframe de pedidos.

Tabla 13 Reseñas

review_id	order_id	review_score	review_comment_title	review_comment_message	review_creation_date
1	1872	4	NaN	NaN	18/01/2018
2	90489	5	NaN	NaN	10/03/2018
3	78883	5	NaN	NaN	17/02/2018
4	27558	5	NaN	Recebi bem antes do prazo e	21/04/2017

6.5 Product category name translation

Creamos el diccionario “dict_category_translation” que contiene la información del data set, para poder usarlo en dataframes posteriores.

Tabla 14 Traducción de nombres de categorías

product_category_name	product_category_name_english
beleza_saude	health_beauty
informatica_acessorios	computers_accessories
automotivo	auto
cama_mesa_banho	bed_bath_table

6.6 Products

Observamos que existían 2 categorías de productos no consideradas en el diccionario creado previamente, por lo que agregamos las categorías faltantes y sus traducciones correspondientes: {"pc_gamer": "pc_gamer", "portateis_cozinha_e_preparadores_de_alimentos": "portable_kitchen_and_food_preparators"}.

En principio las dimensiones de cada producto no nos aportan información relevante para este proyecto, optamos por reemplazar estas medidas por el volumen del producto en unidades de cm³, para posteriormente eliminar columnas no relevantes

También creamos el diccionario “dict_product_id” para almacenar los IDs originales de cada producto y los nuevos IDs asignados, asignamos los nuevos IDs y los nombres traducidos de las categorías de productos.

Por último, se detectó que existían productos sin una categoría asignada, dependiendo de su volumen de ventas podrían representar una cantidad importante de ventas, para no perder esta información se les asignó la categoría “unknown”.

Tabla 15 Productos

product_id	product_category_name	product_weight_g	product_vol_cm3
1	perfumery	225	2240
2	art	1000	10800
3	sports_leisure	154	2430
4	baby	371	2704

6.7 Order items

Cambiamos el formato de la columna “shipping_limit_date” a fecha corta y, a partir de los diccionarios creados anteriormente, aplicamos los nuevos identificadores a las columnas correspondientes.

Finalmente, filtramos para pedidos posteriores a 2016 y que además estén incluidos en el dataframe de pedidos.

Tabla 16 Artículos de pedidos

order_id	order_item_id	product_id	seller_id	shipping_limit_date	price	freight_value
53958	1	4599	475	21/02/2018	49.9	13.37
53958	2	4599	475	21/02/2018	49.9	13.37
36266	1	21359	227	20/10/2017	21.33	15.1
36266	2	21359	227	20/10/2017	21.33	15.1
36266	3	21359	227	20/10/2017	21.33	15.1

6.7.1 Redefinición de “sellers”

Para que la estructura global sea coherente, debemos filtrar la tabla de vendedores tal que solo incluiremos a los vendedores con registros en el dataframe de “order_items”

6.8 Order payments

Asignamos los nuevos identificadores de pedidos, a partir del diccionario correspondiente.

Finalmente filtramos para pedidos que estén incluidos en la tabla de pedidos.

Tabla 17 Pagos de pedidos

order_id	payment_sequential	payment_type	payment_installments	payment_value
1	1	credit_card	1	18.12
1	2	voucher	1	18.59
1	3	voucher	1	2
10	1	credit_card	1	8.34
10	2	voucher	1	161.42

7 Limpieza y redefinición de dataframes

Antes de comenzar a generar visualizaciones es importante revisar si existen registros inconsistentes y su impacto en los registros totales, no se tienen detalles sobre cómo se manejan pedidos en los que se generaron problemas logísticos o técnicos, por lo que estos registros inconsistentes bien podrían ser válidos (o bien no), en principio se eliminarán los registros si tienen poco impacto en el volumen de total de datos.

Por lo que ya se sabe del análisis previo, haremos esta depuración en el dataframe de pedidos (orders) relacionado con las reseñas (order_reviews). Creamos un set en donde iremos almacenando los identificadores de pedidos considerados como inconsistentes, para después eliminar sus registros correspondientes.

Se buscaron registros que cumplan con alguna de las siguientes condiciones:

- Fechas de registro de compra posteriores a fecha de aprobación del pedido, fecha de envío del pedido, fecha de entrega efectiva o estimada de entrega del pedido al cliente, o fecha de envío del pedido posterior a fecha de entrega del pedido, se muestran las primeras filas.

Tabla 18 Muestra de pedidos con fechas inconsistentes

order_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estimated_delivery_date
6438	delivered	20/07/2017	21/07/2017	28/07/2017	25/07/2017	14/08/2017
9554	delivered	02/07/2017	02/07/2017	07/07/2017	06/07/2017	21/07/2017
13488	delivered	16/07/2017	18/07/2017	20/07/2017	19/07/2017	08/08/2017
14475	delivered	20/07/2017	22/07/2017	01/08/2017	26/07/2017	11/08/2017

- Pedidos registrados como entregados (delivered), pero sin fecha de entrega. Se muestran las primeras filas.

Tabla 19 Muestra de pedidos entregados sin fecha de entrega

order_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estimated_delivery_date
3003	delivered	28/11/2017	28/11/2017	30/11/2017	NaT	18/12/2017
20619	delivered	20/06/2018	20/06/2018	25/06/2018	NaT	16/07/2018
43835	delivered	01/07/2018	01/07/2018	03/07/2018	NaT	30/07/2018
79264	delivered	01/07/2018	01/07/2018	03/07/2018	NaT	30/07/2018

- Pedidos registrados como **no** entregados, pero con fechas de entrega.

Tabla 20 Pedidos no entregados con fecha de entrega

order_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estimated_delivery_date
2922	canceled	19/02/2018	19/02/2018	20/02/2018	21/03/2018	09/03/2018

- Pedidos con reseñas creadas **antes** de la compra o antes de fecha de entrega efectiva y estimada de entrega del pedido al cliente (estas 2 últimas condiciones cumpliéndose simultáneamente), ya que según la fuente del data set, al cliente se le habilita mandar una reseña al momento de entrega del pedido o cumplimiento de fecha límite de entrega. Se muestran las primeras filas.

Tabla 21 Muestra de pedidos con fechas de reseñas inconsistentes

order_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estimated_delivery_date	review_creation_date
238	delivered	24/11/2017	28/11/2017	08/12/2017	18/12/2017	19/12/2017	06/12/2017
571	delivered	08/03/2018	09/03/2018	13/03/2018	11/04/2018	04/04/2018	24/03/2018
669	delivered	18/11/2017	18/11/2017	27/11/2017	29/11/2017	05/12/2017	25/11/2017
744	delivered	18/10/2017	18/10/2017	19/10/2017	26/10/2017	10/11/2017	22/10/2017

- Existen solo 3 pedidos cuyo método de pago no está definido, no necesariamente son registros inconsistentes, pero decidimos eliminarlo ya que en fases posteriores agregaría, innecesariamente, una categoría extra de método de pago.

Tabla 22 Pedidos sin método de pago definido

order_id	payment_sequential	payment_type	payment_installments	payment_value
39920	1	not_defined	1	0
1131	1	not_defined	1	0
40236	1	not_defined	1	0

En total se encontraron 451 pedidos con inconsistencias y se calculó el porcentaje que representan respecto del total pedidos, diferenciados por puntaje:

```
review_score    % inconsistencias del total
1.0             0.77
2.0             0.99
```

3.0	0.73
4.0	0.36
5.0	0.36


Se observa que estos pedidos representan menos del 1% de los registros totales para cada puntaje, por lo que eliminaremos estos registros sin impactar considerablemente en los registros totales.

Como último paso de esta etapa, asignaremos los nombres completos a los estados donde se registraron clientes y vendedores, por ejemplo: SP = São Paulo.

La estructura final de los dataframes se puede observar en el [\[Anexo: Estructura de tablas\]](#)

En la imagen siguiente se observa las relaciones entre tablas y los tipos de relación:

Tabla 23 Relaciones entre tablas procesadas



Desde: tabla (columna) ↑	Relación	A: tabla (columna)
order_items (order_id)	* —> 1	orders (order_id)
order_items (product_id)	* —> 1	products (product_id)
order_items (seller_id)	* —> 1	sellers (seller_id)
order_payments (order_id)	* —> 1	orders (order_id)
order_reviews (order_id)	1 —> 1	orders (order_id)
orders (customer_unique_id)	* —> 1	customers (customer_unique_id)

8 Análisis

Para este primer análisis visualizaremos las variables que consideramos interesantes y útiles para resumir el contexto general del ecommerce, tal que permitan tomar decisiones útiles en cuanto a negociación con vendedores, expansión en mercados poco explorados, impacto de demoras logísticas en la opinión de clientes, etc.

Para las visualizaciones que incluyan una escala temporal, no se analizará el último mes de registros, ya que no hay seguridad de que los registros sean completos para ese mes.

Para la generación de visualizaciones y tablas se usó Python y MySQL con los dataframes ya procesados.

8.1 Finanzas

8.1.1 Evolución Mensual

Entre enero y noviembre de 2017 los ingresos crecieron de forma sostenida hasta superar aproximadamente **1 millón de BRL mensuales**, con un pico estacional hacia fin de año, después de una caída considerable en la cantidad de pedidos e ingresos brutos en diciembre de 2017, la evolución fue más o menos constante (hasta donde se tiene registros) manteniéndose en un margen de 6000 a 7000 pedidos mensuales y con ingresos brutos de alrededor de 1.000.000 BRL (reales).

Los picos en el volumen de pedidos e ingresos se pueden atribuir a fechas festivas de fin de año, donde no se observa un gran cambio respecto a las categorías más populares comparadas con otros meses (esto surge de un análisis visual en el dashboard interactivo generado).

Dado que el volumen de pedidos aumenta significativamente durante el último trimestre del año, Olist podría planificar campañas comerciales con mayor presupuesto publicitario y negociar previamente con vendedores y operadores logísticos para absorber el incremento esperado de demanda.

Este patrón debe ser confirmado con más registros anuales, en este caso no se dispone de más registros, por lo que en principio el aumento esperado de las ventas hacia fin de año debe considerarse con recaudo.

Figura 3 Evolución mensual de pedidos






Figura 4 Evolución mensual de ingresos brutos



8.1.2 Desempeño de vendedores


En el eje vertical se disponen los identificadores de los vendedores, a partir de este gráfico se sabe con qué vendedores se deberían priorizar las negociaciones, por supuesto esto también debe complementarse con negociaciones con los socios logísticos.

Figura 5 Top 20 vendedores por volumen de pedidos



En el siguiente gráfico solo se consideró el pago por los artículos en sí, sin considerar el flete.

Figura 6 Top 20 vendedores por facturación



8.1.3 Distribución de métodos de pago

Vemos que la mayoría de clientes prefieren pagar con tarjetas de crédito, esto supone oportunidades de promociones que aumenten las ventas como descuentos o bonos por cantidad de compras, aprovechando la preferencia de los clientes a pagar con tarjeta de crédito.

Tabla 24 Distribución de métodos de pago

payment_type	transactions	percentage
credit_card	74070	74.02
boleto	19072	19.06
voucher	5449	5.45
debit_card	1478	1.48


8.2 Comercial

8.2.1 Análisis por categoría- 2017

Para estos gráficos se consideró un periodo completo de 1 año ya que, en principio, pedidos de ciertas categorías varían según época del año, en este caso solo el año 2017 cuenta con registros completos para todo el año.


Hay una categoría a la que se le asignó el nombre “unknown”, se sugiere analizar qué tipo de productos incluye para poder gestionarlos de manera adecuada tanto en los envíos como en la incorporación de nuevos vendedores, ya que representa un considerable volumen de pedidos.

Figura 7 Top 20 categorías por volumen de pedidos



Solo se consideró el pago por el artículo en sí, sin incluir el flete.

Figura 8 Top 20 categorías por facturación



8.2.2 Análisis por estado

São Paulo concentra el 42% de los clientes, el estado representa alrededor del 22% de la población brasileña, evidenciando una penetración casi dos veces superior a la esperada.

En contraste, estados del Nordeste como **Bahia, Ceará y Maranhão**, así como **Pará** en la región Norte, presentan una participación de clientes considerablemente inferior a su peso demográfico. Esto sugiere oportunidades de expansión comercial y de marketing en regiones donde el e-commerce aún tiene una menor adopción dentro de la base de clientes de Olist, o donde la empresa posee una menor presencia relativa.

Figura 9 Clientes por estado





Figura 10 Ingresos brutos por estado



Se calculó que aproximadamente solo el **2.7%** de los clientes vuelven a realizar una compra, se sugiere implementar campañas de fidelización.

8.3 Logística

8.3.1 Distribución de estado de pedidos

Vemos que el 97% de los pedidos se completan (no necesariamente a tiempo), aún así también se observa que existen problemas logísticos a tratar, ya que muchos pedidos, además de ser cancelados o no estar disponibles, figuran como pedidos incompletos.

Por supuesto esto más allá de eventos incontrolables como accidentes o siniestros.

Tabla 25 Distribución de estado de pedidos


order_status	count	percentage
delivered	95819	97.12
shipped	1097	1.11
unavailable	602	0.61
canceled	541	0.55
processing	299	0.3
invoiced	296	0.3
created	5	0.01
approved	2	0

8.3.2 Distribución de tiempos de entrega

La mayoría de las entregas se realizan entre 1 a 20 días después de la compra, siendo el periodo más común alrededor de los 10 días. Existen varios outliers que pueden explicarse por sucesivas reentregas, pedidos especiales que demandan largos periodos de espera, entre otros.

Este análisis debe complementarse con la relación entre tiempos de entrega y el puntaje en reseñas.

Figura 11 Distribución de tiempos de entrega



8.3.3 Tasa de demoras por estado


El siguiente gráfico presenta un resumen muy interesante, se observa que aunque **Río de Janeiro** concentrada gran parte del mercado, también presenta una de las mayores tasa de demoras (alrededor del 12%), esta visualización

ofrece un análisis integral para la toma de decisiones en cuanto a concentrar esfuerzos para mejorar el desarrollo logístico según ciertos estados, evaluando su impacto según participación en cantidad de pedidos.

Se sugiere concentrar esfuerzos en mejorar la estructura logística **Río de Janeiro** ya que representan gran parte del volumen de pedidos, pero a su vez tiene alta tasa de demoras en la entrega de pedidos.

Hay estados con una alta tasa de demora, pero con una cantidad pequeñas de pedidos, por lo que en principio no son prioritarios, aún así se recomienda instar a los vendedores de dichos estados a analizar y mejorar su estructura logística, ya que también afectan a la imagen de la empresa.


Figura 12 Tasas de demora por estado



8.3.4 Tasa de demoras por vendedor

Aunque los vendedores con mayores tasas de demoras presentan un bajo volumen de pedidos, se sugiera instar a dichos vendedores a analizar y mejorar sus procesos de preparación y entrega de pedidos.

Figura 13 Top 20 vendedores por tasa de demora



8.4 Calidad

8.4.1 Reseñas generales por vendedor

En MySQL se generó una tabla que incluye las reseñas promedio por vendedor y la cantidad de pedidos que manejan, este registro permite analizar la opinión de los clientes para cada vendedor, y su impacto en el ecommerce según volumen de pedidos, pudiendo así priorizar trabajos conjuntos con vendedores con opiniones relativamente negativas de vendedores y con un alto impacto en la empresa, se muestra a continuación algunos registros.


Tabla 26 Muestra de reseñas generales por vendedor

seller_id	average_review	reviewed_orders
798	3.98	1803
2464	3.85	1744
1414	4.15	1616
475	4.14	1388
1874	4.17	1286
391	4.2	1253
2208	4.27	1136
988	4.03	1125
2618	4.15	1114
2346	4.19	1051
1183	3.49	951

8.4.2 Relación entre entregas y satisfacción de clientes


Se observa una fuerte relación entre las entregas a tiempo y la satisfacción de clientes, esto también se puede complementar con la relación entre adelantos o atrasos en las entregas y los puntajes asignados, así como se ve en la siguiente tabla.

Figura 14 Distribución de reseñas para entregas a tiempo y entregas atrasadas



Cabe resaltar que la mayor parte de los clientes realizan una reseña después de que se completan sus pedidos, por lo que este último gráfico representa fielmente la opinión de los clientes.

Figura 15 Review score promedio por rangos de adelanto o atraso




Este cuadro confirma la relación planteada anteriormente, además se observa que la calificación promedio no difiere considerablemente entre una entrega a tiempo o adelantada, en cambio se ve que cuando mayores son los días de atraso la impresión negativa de los clientes crece considerablemente.

8.4.3 Relación entre tasas de demora y review score promedio

A partir del dashboard interactivo se extrajeron las tasas de demoras y el review score promedio para cada estado, a partir de estos datos se generó un gráfico de dispersión relacionando ambas variables.

Como era de esperarse, se confirma que una mala impresión de los clientes está directamente relacionada con la tasa de demoras.

Figura 16 Relación entre tasas de demora y review score promedio por estado



9 Conclusiones

- Olist muestra un crecimiento sostenido en ventas durante el período analizado; sin embargo, la **tasa de recompra del 2,7 %** indica que ese crecimiento depende principalmente de la adquisición de nuevos clientes. Incrementar la retención representa una de las principales oportunidades para mejorar el crecimiento a largo plazo, un primer paso para este objetivo podría ser implementar programas de fidelización y campañas poco invasivas de email marketing a clientes con registros de compra.
- La satisfacción permanece relativamente estable mientras las entregas son puntuales o incluso adelantadas. Las entregas puntuales mantienen valoraciones cercanas a **4 estrellas**, mientras que retrasos superiores a cinco días reducen la valoración promedio por debajo de **2 estrellas**, evidenciando una fuerte relación entre desempeño logístico y experiencia del cliente; y en consecuencia, de la reputación de la empresa. También se evidenció que en los estados donde se producen mayores tasas de demora, es decir cantidad de pedidos atrasados respecto del total de pedidos, también se tienen menores puntajes en las reseñas, evidenciando una relación inversa aproximadamente lineal.
- São Paulo constituye el principal motor comercial de Olist, concentrando más de un tercio de la facturación. Esta elevada concentración sugiere tanto una fortaleza como un riesgo, ya que el desempeño del negocio depende en gran medida de un único mercado regional. Estados del Nordeste como **Bahia, Ceará y Maranhão**, y Norte como **Pará** muestran una presencia relativa menor tomando en cuenta su peso demográfico, lo que sugiere potencial para ampliar la cobertura comercial mediante campañas regionales.
- La tabla de reseñas por vendedor permite priorizar trabajos colaborativos para mejorar la calidad de productos y estructura logística con vendedores que manejan grandes volúmenes de pedidos y con opiniones poco satisfactorias de los clientes, por ejemplo, con el vendedor con id **1183** y reseña promedio de **3.5** al cual se le hicieron casi 1000 pedidos. Mejorando así la satisfacción de los clientes y en consecuencia la confianza en la empresa, esto en principio incrementará el volumen de clientes potenciales.

10 Anexo: Estructura de tablas

=====

customers

=====

```
<class 'pandas.DataFrame'>
Index: 95628 entries, 0 to 99440
Data columns (total 4 columns):
#   Column                      Non-Null Count  Dtype
---  -
0   customer_unique_id          95628 non-null  int64
1   customer_zip_code_prefix    95628 non-null  int64
2   customer_city                95628 non-null  str
3   customer_state              95628 non-null  str
dtypes: int64(2), str(2)
memory usage: 3.6 MB
```

Valores únicos por columna:

customer_unique_id	95628
customer_zip_code_prefix	14973
customer_city	4114
customer_state	27

dtype: int64

=====

sellers

=====

```
<class 'pandas.DataFrame'>
Index: 3065 entries, 0 to 3094
Data columns (total 4 columns):
#   Column                      Non-Null Count  Dtype
---  -
0   seller_id                   3065 non-null  int64
1   seller_zip_code_prefix      3065 non-null  int64
2   seller_city                  3065 non-null  str
3   seller_state                 3065 non-null  str
dtypes: int64(2), str(2)
memory usage: 119.7 KB
```

Valores únicos por columna:

seller_id	3065
seller_zip_code_prefix	2232
seller_city	606
seller_state	22

dtype: int64

=====

orders

=====

```
<class 'pandas.DataFrame'>
Index: 98661 entries, 0 to 99440
Data columns (total 10 columns):
#   Column                      Non-Null Count  Dtype
---  -
0   order_id                    98661 non-null  int64
1   customer_unique_id          98661 non-null  int64
2   order_status                 98661 non-null  str
3   order_purchase_timestamp     98661 non-null  datetime64[us]
```

```

4  order_approved_at      98563 non-null  datetime64[us]
5  order_delivered_carrier_date  96985 non-null  datetime64[us]
6  order_delivered_customer_date  95819 non-null  datetime64[us]
7  order_estimated_delivery_date  98661 non-null  datetime64[us]
8  delivery_days          95819 non-null  float64
9  advance_or_delay_days    95819 non-null  float64
dtypes: datetime64[us](5), float64(2), int64(2), str(1)
memory usage: 8.3 MB

```

Valores únicos por columna:

```

order_id      98661
customer_unique_id  95628
order_status      8
order_purchase_timestamp  603
order_approved_at  597
order_delivered_carrier_date  511
order_delivered_customer_date  604
order_estimated_delivery_date  420
delivery_days    139
advance_or_delay_days  190
dtype: int64

```

```

=====
order_reviews
=====
<class 'pandas.DataFrame'>
Index: 97898 entries, 0 to 99223
Data columns (total 6 columns):
#   Column                Non-Null Count  Dtype
---  -
0   review_id             97898 non-null  int64
1   order_id              97898 non-null  int64
2   review_score           97898 non-null  int64
3   review_comment_title   11497 non-null  str
4   review_comment_message 40368 non-null  str
5   review_creation_date   97898 non-null  datetime64[us]
dtypes: datetime64[us](1), int64(3), str(2)
memory usage: 5.2 MB

```

Valores únicos por columna:

```

review_id      97552
order_id      97898
review_score      5
review_comment_title  4513
review_comment_message  35770
review_creation_date    583
dtype: int64

```

```

=====
category_translation
=====
<class 'pandas.DataFrame'>
RangeIndex: 71 entries, 0 to 70
Data columns (total 2 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   product_category_name                 71 non-null     str
1   product_category_name_english         71 non-null     str

```

```
dtypes: str(2)
memory usage: 1.2 KB
```

```
Valores únicos por columna:
product_category_name          71
product_category_name_english  71
dtype: int64
```

```
=====
products
=====
```

```
<class 'pandas.DataFrame'>
RangeIndex: 32951 entries, 0 to 32950
Data columns (total 4 columns):
#   Column                Non-Null Count  Dtype
---  -
0   product_id            32951 non-null  int64
1   product_category_name 32951 non-null  str
2   product_weight_g      32949 non-null  float64
3   product_vol_cm3       32949 non-null  float64
dtypes: float64(2), int64(1), str(1)
memory usage: 1.0 MB
```

```
Valores únicos por columna:
product_id          32951
product_category_name    74
product_weight_g      2204
product_vol_cm3       4525
dtype: int64
```

```
=====
order_items
=====
```

```
<class 'pandas.DataFrame'>
Index: 111817 entries, 0 to 112649
Data columns (total 7 columns):
#   Column                Non-Null Count  Dtype
---  -
0   order_id              111817 non-null  int64
1   order_item_id         111817 non-null  int64
2   product_id            111817 non-null  int64
3   seller_id             111817 non-null  int64
4   shipping_limit_date    111817 non-null  datetime64[us]
5   price                 111817 non-null  float64
6   freight_value         111817 non-null  float64
dtypes: datetime64[us](1), float64(2), int64(4)
memory usage: 6.8 MB
```

```
Valores únicos por columna:
order_id          97959
order_item_id      21
product_id        32685
seller_id         3065
shipping_limit_date  534
price             5955
freight_value     6972
dtype: int64
```

```

=====
order_payments
=====
<class 'pandas.DataFrame'>
Index: 103077 entries, 0 to 103885
Data columns (total 5 columns):
#   Column                      Non-Null Count  Dtype
---  -
0   order_id                    103077 non-null  int64
1   payment_sequential          103077 non-null  int64
2   payment_type                 103077 non-null  str
3   payment_installments         103077 non-null  int64
4   payment_value                103077 non-null  float64
dtypes: float64(1), int64(3), str(1)
memory usage: 4.7 MB

Valores únicos por columna:
order_id          98661
payment_sequential    29
payment_type         4
payment_installments  24
payment_value        28940
dtype: int64

```